Laporan Proyek Akhir

Twitter Sentiment Explorer - Program Python Berbasis Menu CLI

1. Dataset

Item	**Keterangan**
Nama dataset	Twitter Entity Sentiment Analysis (file yang dipakai: twitter_validation.csv)
link kaggle	https://www.kaggle.com/datasets/jp797498e/twitter-entity-sentiment-analysis
Lisensi	CC0: Public Domain (boleh dipakai untuk pendidikan)
Ukuran	1.000 baris, satu file CSV, satu baris = satu tweet, tanpa baris header
Data Pribadi	Tweet berisi @username. Program mengganti semuanya menjadi @user saat memuat data, sehingga tidak ada nama akun yang disimpan atau ditampilkan.

Alasan memilih dataset: Data ini adalah tweet nyata sehingga hasilnya terasa bermakna. Ukurannya (1.000 baris) pas dengan syarat 200 sampai 2.000 baris tanpa perlu dipangkas. Kolomnya sederhana dan lengkap, dengan dua kolom kategori (entitas dan sentimen) yang cocok untuk fitur pencarian, filter, ranking, dan ringkasan. Teksnya yang berantakan (huruf kapital campur, tanda hubung, baris baru) juga membuat fungsi pembersih teks benar-benar berguna.

2. Kolom Yang digunakan dan yang dilewati

no	Kolom	Tipe data	Status	Pejelasan
1	id tweet	int	dipakai	Pengenal tweet. Baris dengan ID bukan angka dilewati.
2	entitas	str	dipakai	Game atau perusahaan yang dibicarakan (32 macam, misal. FIFA, Google).
3	sentimen	str	dipakai	Positive, Negative, Neutral, atau Irrelevant. Nilai lain membuat baris dilewati.
4	teks tweet	str	dipakai	Baris baru dihapus dan @username disamarkan.

- **Kolom yang dilewati**: tidak ada. File hanya punya 4 kolom dan semuanya dipakai.
- **Sel kosong**: sudah diperiksa, keempat kolom terisi di semua 1.000 baris, jadi tidak ada penanganan khusus. Jika suatu baris punya entitas atau teks kosong, baris itu dilewati dan dihitung.

- **File lain di dataset asli**: twitter_training.csv (puluhan ribu baris) tidak dipakai karena melebihi batas 2.000 baris.
- **Nilai turunan** (tidak ada di file, dihitung program): panjang tweet, jumlah kata, rata-rata panjang,persentase positif dan negatif.

3. Cara menjalankan dan tes

Hanya butuh Python 3 (pustaka standar saja, tanpa pandas atau numpy). Buka terminal di dalam folder proyek. File twitter_validation.csv harus berada satu folder dengan main.py.

```
python main.py          # menjalankan program
python -m unittest      # menjalankan unit test (23 tes)
```

Saat program mulai, tampil pesan seperti Berhasil memuat 1000 record, 0 baris tidak terbaca dilewati. lalu menu muncul dan berulang sampai pengguna memilih 6 (Keluar). Hasil tes yang benar: **Ran 23 tests ...OK**.

4. Struktur File

File	Tugas
models.py	Konstanta dan class Tweet (satu record) serta TweetCollection (kumpulan record).
text_utils.py	Fungsi string: membersihkan teks, menyamarkan @username, memotong teks.
data_loader.py	Membaca CSV, memeriksa tiap baris, melewati dan menghitung baris rusak.
analysis.py	Logika fitur: cari, filter, urutkan (insertion sort buatan sendiri), ringkas, hitung persentase.
main.py	Menu, input dan validasi, serta tampilan tabel rata.
test_project.py	23 unit test: input normal, kasus tepi, dan input salah.

5. Fungsi Setiap Fitur

Menu	Fitur	Apa yang di lakukan	Fungsi Utama
1	Search Keyword	Mencari tweet yang mengandung kata kunci. Tidak peduli huruf kapital, tanda hubung, aksen, atau spasi berlebih. Hasil berupa tabel.	search_tweets, clean_text
2	Daftar Entitas/sentimen	Memfilter tweet berdasarkan entitas dan, jika diinginkan,	filter_tweets, find_entity

		sentimen. Mengetik ? menampilkan daftar entitas. Menampilkan 10 hasil pertama.	
3	Top N Tweet terpanjang	Mengurutkan tweet dari yang terpanjang dengan insertion sort buatan sendiri, lalu mengambil N pertama dengan slicing. Menampilkan juga jumlah tweet short/medium/long.	top_longest, sort_descending, categorize_length
4	Ringkasan Sentimen per entitas	Untuk setiap entitas: jumlah tweet per sentimen, % positif, % negatif, dan rata-rata panjang. Diurutkan dari % positif tertinggi.	summarize_all, summarize_entity
5	Bandingkan 2 Entitas	Menampilkan dua ringkasan berdampingan dan menyebut entitas mana yang lebih positif.	summarize_entity
6	Keluar	Mengakhiri loop menu.	main

Aturan yang berlaku di semua fitur: setiap ketikan divalidasi (huruf saat diminta angka, angka di luar rentang, input kosong, entitas tidak dikenal) dengan pesan jelas lalu prompt baru, tanpa crash. Baris CSV yang tidak terbaca dilewati dan jumlahnya dilaporkan. Pembagian dilakukan lewat safe_divide sehingga tidak pernah dibagi nol.

6.Keterbatasan Yang diketahui

- Label sentimen berasal dari dataset dan belum tentu sesuai penilaian manusia.
- Teks tweet dipotong 55 karakter di tabel dan hanya 10 hasil pertama yang ditampilkan di pencarian dan filter.
- Satu-satunya kolom angka asli adalah ID, sehingga analisis memakai nilai turunan (panjang tweet, persentase) dan relatif sederhana.
- Pencarian memakai kecocokan potongan teks (substring), bukan pencarian kata utuh. Kata kunci pendek seperti "ps" dapat cocok dengan banyak kata.
- Nama entitas dipakai apa adanya dari dataset, termasuk yang tampak keliru seperti WorldOfCraft.
- Seluruh data dimuat ke memori sekaligus. Ini cukup untuk 1.000 baris tetapi tidak cocok untuk data yang sangat besar.

7. Link Video penjelasan

https://youtu.be/ZFn0IKo5vPU

8. Link Repo

https://github.com/AndraKabayan/twitter_sentiment_explorer

9. Tabel Konsep, File, dan Fungsi

Konsep	File	Fungsi/Bagian	Cara Digunakan
Variabel dan tipe data	models.py	Konstanta CSV_FILE, VALID_SENTIMENTS, SHORT_LIMIT; Tweet.__init__	Nilai tetap dalam konstanta huruf kapital; atribut bertipe int, str, dan list.
Input dan output	main.py	ask_int; print_tweets	input() dalam loop validasi; hasil dicetak dengan f-string berkolom rata (:<24, :>4).
Operator	analysis.py	percent; average_length; filter_tweets	Aritmetika (persentase, rata-rata), relasional (<, ==), logika (and, or, not).
Kondisional	analysis.py	categorize_length	if / elif / else memilih 3 hasil: short, medium, long. Juga dipakai di ask_int (main.py).
Perulangan	main.py, analysis.py	main (while running); search_tweets (for)	while untuk menu yang berulang; for untuk memproses setiap record.
Fungsi	analysis.py	safe_divide; summarize_entity; top_longest	Fungsi dengan parameter dan nilai kembalian.
List	analysis.py	filter_tweets; top_longest	Semua record disimpan di list; list hasil dibuat baru; slicing ranked[:n].
String	text_utils.py	clean_text; mask_handles; shorten	lower, strip, split, replace, join; menghapus aksen dan tanda hubung.
Class (bonus)	models.py	Tweet; TweetCollection	Tweet punya __init__ dan __str__; TweetCollection menampung list Tweet
Unit test	test_project.py	TestTextUtils, TestLoader, TestAnalysis, TestModels	23 tes untuk input normal, kasus tepi (list kosong, nol), dan input salah.